Experimento 1: recuperación y reranking

Examen Parcial CC0F4 - Tópicos de Ciencia de la Computación I

¿De qué trata el experimento?

- Un auditor pregunta por un proceso del SEACE y el sistema debe encontrar los pasajes donde está la respuesta
  - Ejemplo: ¿En qué proceso se compró el tóner Xerox con código de referencia 006R01830?
- Se comparan tres formas de buscar sobre el mismo material
  - A: búsqueda densa (embeddings + FAISS)
  - B: A + BM25 + fusión RRF
  - C: B + reranking con un Cross-Encoder
- Pregunta: ¿cómo cambian la recuperación de evidencia y su costo al agregar cada pieza?
- No se busca probar que un método es mejor en general, solo medir qué cambia y cuánto cuesta

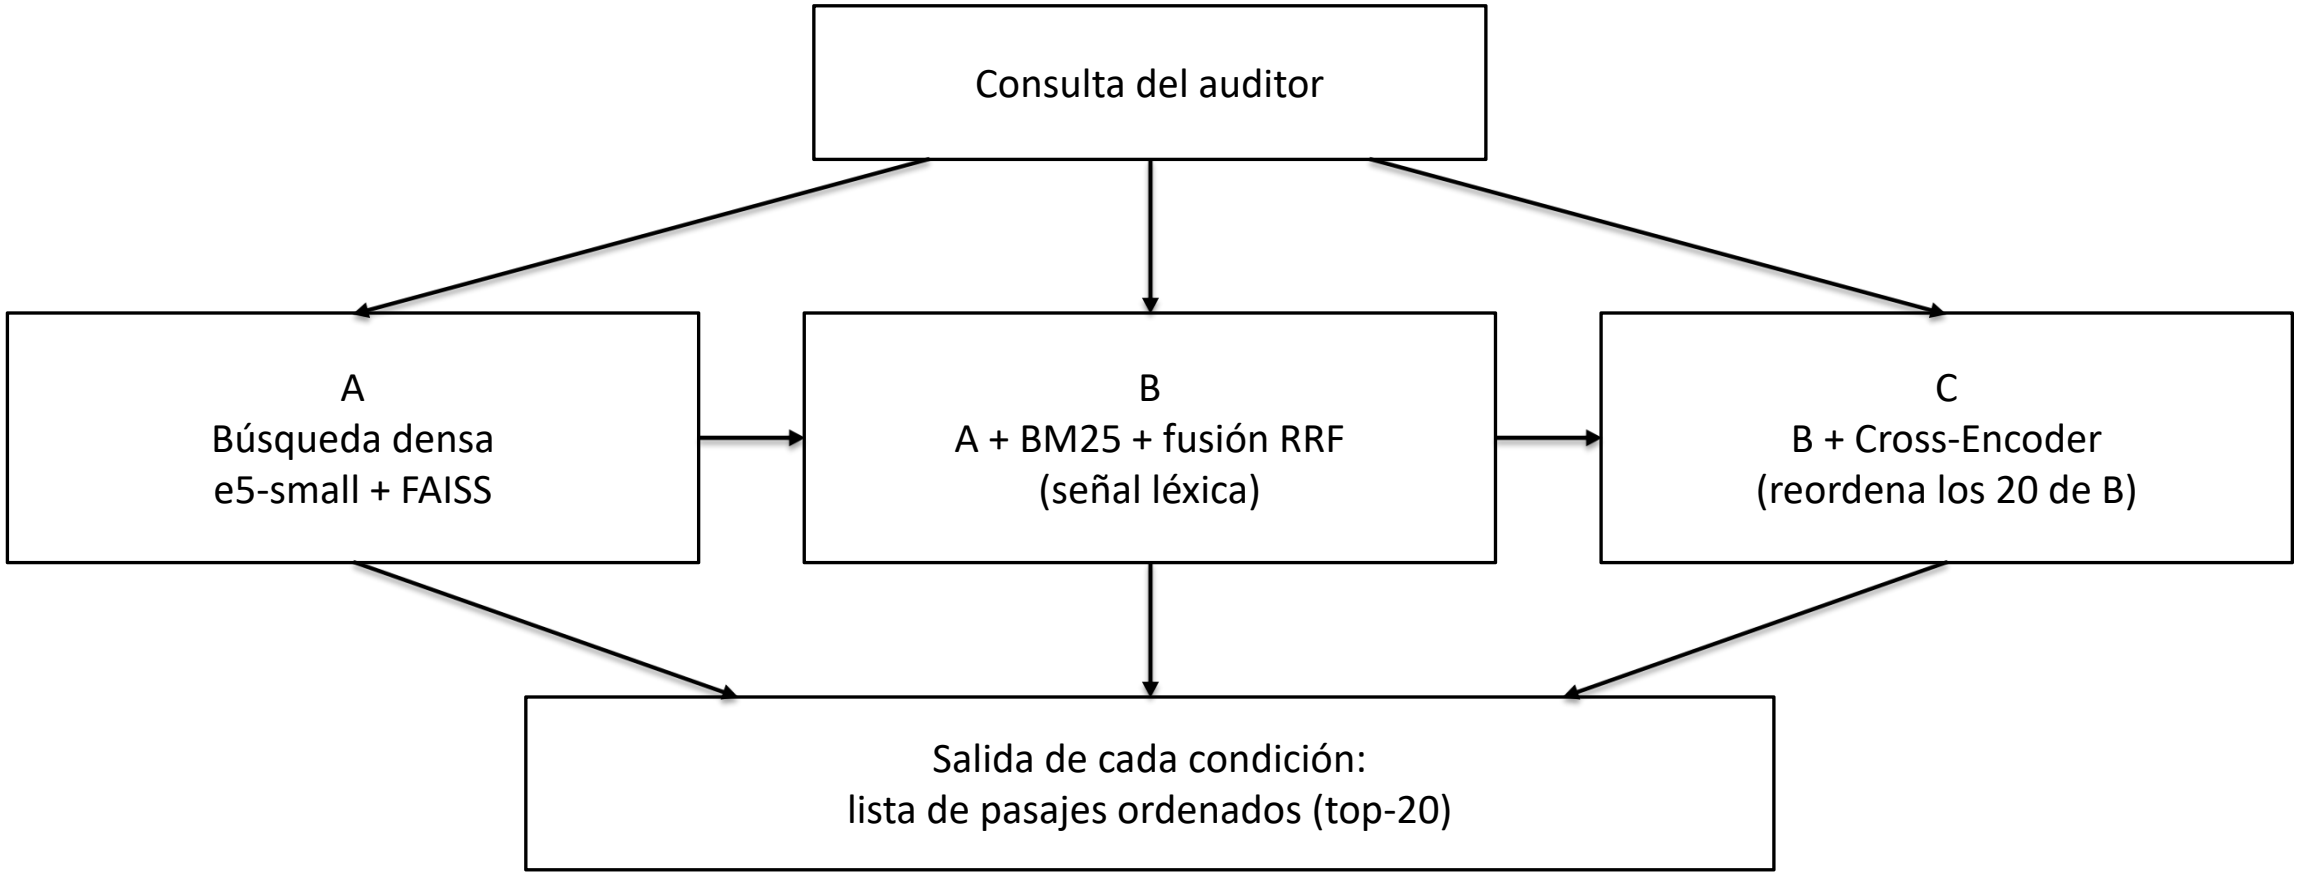
Qué entra al experimento

- Corpus: 55 procesos reales del SEACE partidos en 426 pasajes
  - Un pasaje es una parte del proceso: convocatoria, ítems, cronograma, postores, resultado, contrato
  - Cada pasaje tiene un id, por ejemplo E49-P05 (proceso E49, pasaje 5)
- 22 consultas: 20 con qrels y 2 de control sin evidencia en el corpus (Q21 y Q22)
  - Los 2 controles no entran en las métricas de este experimento, los usa el experimento 2
- 11 de las 20 consultas son difíciles
  - Distractores reales (cuatro compras de Office, dos de Adobe), códigos exactos, paráfrasis,
  - una consulta numérica, una contradicción y dos que necesitan varios pasajes
- Los qrels (qué pasajes son relevantes) se anotaron leyendo los pasajes y se congelaron con SHA-256
  - Se fijaron antes de correr cualquier sistema

Unidad de recuperación: el pasaje con su encabezado

- En A, B y C lo que se busca es un pasaje, con el encabezado de su proceso delante
  - Encabezado: nomenclatura y objeto del proceso | entidad
  - Así cada pasaje lleva la evidencia y también lo que lo identifica
- Referencia A0: la configuración de la PC2
  - Chunks de 180 palabras con 1 pasaje de solapamiento (86 chunks en total), solo búsqueda densa
  - En la PC2 el chunk podía separar la buena pro del ítem que la identifica (error N5)
- A0 se corre para medir el cambio de unidad en vez de suponerlo
- Los resultados de los chunks de A0 se pasan a pasajes para compararlos con los mismos qrels

Qué se compara



- A0 (referencia): la configuración de la PC2, chunks de 180 palabras y solo búsqueda densa

A: búsqueda densa

- El modelo e5-small convierte la consulta y cada pasaje en un vector de 384 números
- FAISS compara el vector de la consulta con los 426 vectores y devuelve los más parecidos (top-20)
- Compara significado, no palabras: entiende paráfrasis
  - Ejemplo: "de su propiedad" y "equipo propio" quedan cerca
- Su punto débil son los códigos y nombres casi iguales
  - Q06: el proceso tiene cinco tóneres Xerox con códigos parecidos y para el embedding todos se parecen
  - El pasaje correcto queda en el puesto 4 (no entra al top-3)

B: A + BM25 + fusión RRF

- BM25 busca por palabras exactas y da más peso a las palabras raras
  - El código 006r01830 aparece en un solo pasaje, así que BM25 lo detecta enseguida
- RRF junta la lista del denso y la de BM25 en una sola, usando la posición de cada pasaje
  - puntaje = suma de 1 / (60 + posición) en cada lista
  - Ejemplo: puesto 4 en el denso y puesto 1 en BM25 da 1/64 + 1/61 = 0,032
  - Un pasaje que solo aparece en una lista, en el puesto 1, da 1/61 = 0,016
- Así sube lo que ambas listas consideran bueno, sin comparar puntajes de escalas distintas
- De A a B cambian dos cosas a la vez (la señal léxica y la fusión)
  - No se puede saber cuál de las dos produce cada cambio

C: B + Cross-Encoder

- El Cross-Encoder lee la consulta y el pasaje juntos y decide qué tan bien se corresponden
  - El denso, en cambio, vectoriza la consulta y el pasaje por separado
- Solo reordena los 20 candidatos que entrega B
  - No puede recuperar un pasaje que B no trajo
  - Por eso B frente a C mide el efecto incremental del reranker
- Es más fino pero más lento: hay que correrlo una vez por cada candidato (20 pares por consulta)
- Modelo: mmarco-mMiniLMv2, multilingüe, entrenado con datos de búsqueda

Qué se mantiene igual

- Mismos 426 pasajes y mismas 20 consultas con qrels (benchmark congelado)
- Mismo modelo de embeddings (e5-small con prefijos query:/passage:, minúsculas y normalización L2)
- Misma profundidad: cada recuperador entrega 20 candidatos
- BM25 con k1 = 1,5 y b = 0,75; RRF con k = 60
- Misma semilla (42), misma máquina (CPU, 8 hilos) y una llamada de calentamiento antes de medir
- Por eso las diferencias entre A, B y C se pueden atribuir a la pieza que se agregó

Cómo se mide

- Recall@k: de los pasajes relevantes, qué fracción aparece en los k primeros (k = 1, 3, 5)
- MRR: 1 dividido entre la posición del primer pasaje relevante (puesto 1 = 1; puesto 4 = 0,25)
- nDCG@5: premia que los relevantes estén arriba, no solo que estén
- Latencia por etapa (media y p95): denso, BM25, RRF y Cross-Encoder
- Bootstrap pareado (5000 remuestreos): intervalo de confianza de la diferencia entre dos condiciones
- Tipo de fallo por consulta: acierta, recupera parte, mal ordenado o no lo trae
- Los qrels son binarios (relevante o no) y están sobre el id del pasaje

Ejemplo de métricas: consulta Q06

Condición	Posición del pasaje E49-P05	Recall@3	MRR
A0	5	0,00	0,20
A	4	0,00	0,25
B	1	1,00	1,00
C	1	1,00	1,00

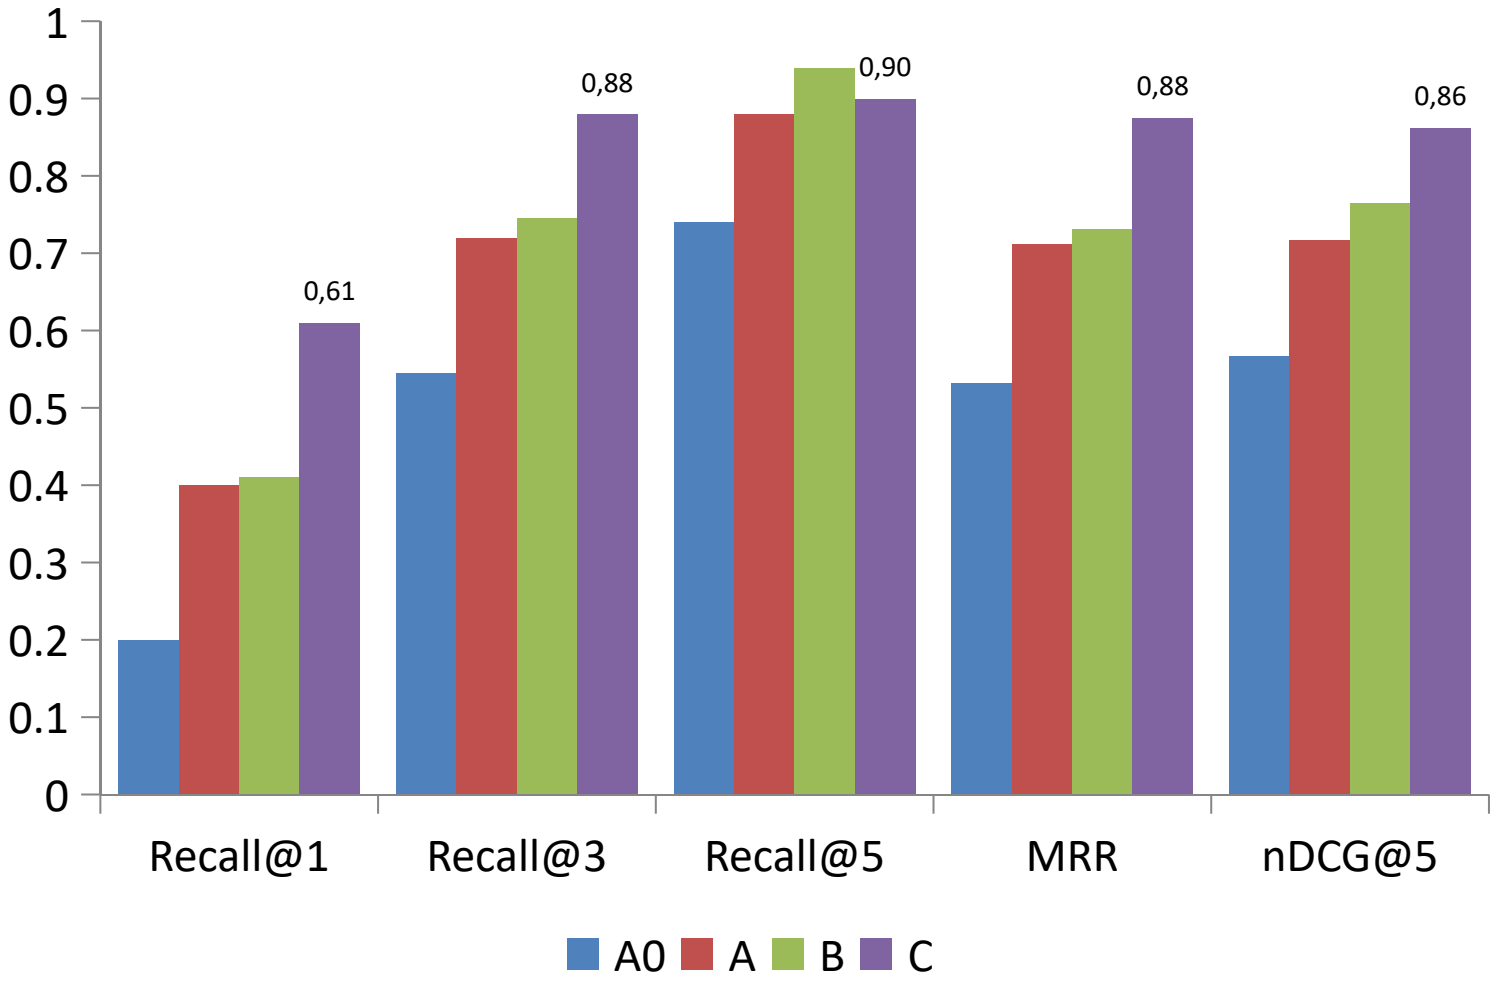
- Q06 tiene un solo pasaje relevante
  - Si queda en el puesto 4 o 5, Recall@3 vale 0, pero Recall@5 sí lo cuenta
  - MRR baja a 0,25 o 0,2: sigue premiando que esté cerca de arriba
- En B y C el pasaje sube al puesto 1 y las dos métricas valen 1
- Cuando una consulta tiene dos pasajes relevantes, Recall@1 no puede pasar de 0,5
  - Por eso el Recall@1 promedio de C (0,61) es menor que su MRR (0,88)

Resultados: métricas

Condición	Recall@1	Recall@3	Recall@5	MRR	nDCG@5
A0 (PC2)	0,20	0,55	0,74	0,53	0,57
A (denso)	0,40	0,72	0,88	0,71	0,72
B (A + BM25 + RRF)	0,41	0,75	**0,94**	0,73	0,77
C (B + Cross-Encoder)	**0,61**	**0,88**	0,90	**0,88**	**0,86**

- En negrita, el mejor valor de cada columna
- Media sobre las 20 consultas con qrels
- C gana en Recall@1, Recall@3, MRR y nDCG@5; B gana en Recall@5

Resultados: gráfico



- Cada grupo de barras es una métrica
- Cada color es una condición
- Se rotulan los valores de C
- A0 es la más baja en todo

Interpretación de las métricas

- La unidad importó: de A0 a A el MRR sube de 0,53 a 0,71
  - Solo se cambió de chunks de 180 palabras a pasaje con encabezado, con el mismo modelo
- B casi no se distingue de A
  - Recall@5 sube de 0,88 a 0,94 y el MRR apenas de 0,71 a 0,73
- C mejora sobre todo el principio de la lista
  - Recall@1 sube de 0,41 a 0,61 y el MRR de 0,73 a 0,88
- Recall@5 de C (0,90) es menor que el de B (0,94)
  - El reranker ordena mejor, pero en algunas consultas saca del top-5 un pasaje que B tenía dentro

Costo: latencia por etapa

Etapa	Tiempo medio (ms)
Denso (e5 + FAISS)	22,3
BM25	1,0
RRF	0,05
Cross-Encoder (20 pares)	1043

Condición	Total medio (ms)	p95 (ms)
A0	25	31
A	22	24
B	23	26
C	1066	2011

- BM25 y RRF casi no cuestan: B tarda lo mismo que A
- El Cross-Encoder domina el costo: C tarda unas 46 veces lo que B
  - Hay que evaluar 20 pares consulta-pasaje por cada consulta
- Medido en CPU (AMD Ryzen 7, 8 hilos) y una sola corrida, así que sirve de orden de magnitud

¿Las diferencias son reales? Bootstrap

Comparación	Recall@3	MRR	nDCG@5
B - A	+0,025 [-0,125; 0,175]	+0,019 [-0,099; 0,148]	+0,049 [-0,028; 0,130]
C - B	+0,135 [-0,005; 0,295]	+0,144 [-0,008; 0,296]	+0,097 [-0,026; 0,209]
C - A	+0,160 [0,020; 0,325]	+0,163 [0,025; 0,305]	+0,145 [0,028; 0,253]
A - A0	+0,175 [-0,025; 0,375]	+0,179 [0,051; 0,319]	+0,150 [0,034; 0,270]

- Cada celda: diferencia de medias y su intervalo de confianza al 95 %
- Si el intervalo incluye el 0, con 20 consultas no se puede distinguir la diferencia de cero
- B - A y C - B cruzan el cero en las tres métricas
- C - A es la única comparación con las tres métricas por encima de cero
- A - A0 también, pero solo en MRR y nDCG@5

Tipos de fallo por consulta

Condición	RETRIEVAL_OK	PARTIAL_RECALL	RANKING_ERROR	RETRIEVAL_MISS
A0	10	2	7	1
A	12	5	3	0
B	13	4	2	1
C	16	3	0	1

- Corte en k = 3, sobre las 20 consultas
  - RETRIEVAL_OK: todos los pasajes relevantes están en el top-3
  - PARTIAL_RECALL: algunos están en el top-3, otros no
  - RANKING_ERROR: están entre los candidatos, pero ninguno en el top-3
  - RETRIEVAL_MISS: ninguno está entre los candidatos
- De A0 a C los aciertos pasan de 10 a 16 y los errores de orden de 7 a 0

Consultas analizadas: donde BM25 y el reranker ayudan

Consulta	Pasaje relevante	A	B	C
Q06	E49-P05	4	1	1
Q20	E12-P06	4	5	1
Q12	E50-P05	3	3	1

- Posición del pasaje relevante en cada condición (1 = primero)
- Q06 (código 006R01830): BM25 pesa el código, que está en un solo pasaje, y B lo sube del puesto 4 al 1
- Q20 (antivirus del Programa Juntos): A y B dejan la buena pro en los puestos 4 y 5; C la sube al 1
- Q12 (único postor del tomógrafo Siemens): el pasaje de postores pasa del puesto 3 al 1 con C
    - El Cross-Encoder ve "único postor" junto a "Número de postores registrados: 1"

Consultas analizadas: donde fallan

Consulta	Pasaje	A	B	C
Q03	E45-P02	1	1	9
Q17	E37-P06	3	4	2
Q13	E48-P06	15	fuera	fuera

- Q03 (Adobe admitiendo equivalente): C baja el ítem del puesto 1 al 9
  - Prefiere pasajes de Adobe sin equivalente (el distractor): premia "Adobe" y no pesa la condición
- Q17 (Office 365 del FONDEPES): B baja el pasaje del puesto 3 al 4 al adelantar a INACAL (también Office 365)
  - C lo deja en el puesto 2, todavía detrás del distractor
- Q13 (adjudicado más de 30 % sobre el valor referencial): falla en todas
  - Hay que comparar números y ningún recuperador lo hace; B y C ni siquiera lo traen entre los 20

Resultados negativos

- El Recall@5 de C es menor que el de B
  - En Q03 y Q14 el reranker empuja fuera del top-5 un pasaje que B tenía dentro
- B no se distingue de A
  - BM25 gana en Q06 y Q02, pero la fusión baja el pasaje correcto en otras (Q17, Q10, Q11)
  - En MRR, B empeora en 6 consultas y mejora en 3
- C - B también cruza el cero: solo C - A es distinguible de cero
- Q13 no la resuelve ninguna condición
- Se conservan porque limitan lo que se puede afirmar del experimento

Conclusión

- C es la mejor en Recall@1, Recall@3, MRR y nDCG@5, pero la diferencia es clara solo frente a A, no frente a B
  - Y cuesta cerca de 1 segundo por consulta en CPU, unas 46 veces lo que B
- El cambio más barato y con efecto claro fue la unidad de recuperación (A frente a A0)
  - El error N5 de la PC2 era de segmentación, no del modelo
- BM25 + RRF ayuda con códigos exactos (Q06) y perjudica cuando adelanta un distractor (Q17)
- No se declara que C sea mejor en general
  - Son 20 consultas anotadas por nosotros y el intervalo de C - B incluye el cero
- Los 5 primeros resultados de C son la evidencia que recibe el LLM en el experimento 2