Experimento 2: RAG y evidencia

Examen Parcial CC0F4 - Tópicos de Ciencia de la Computación I

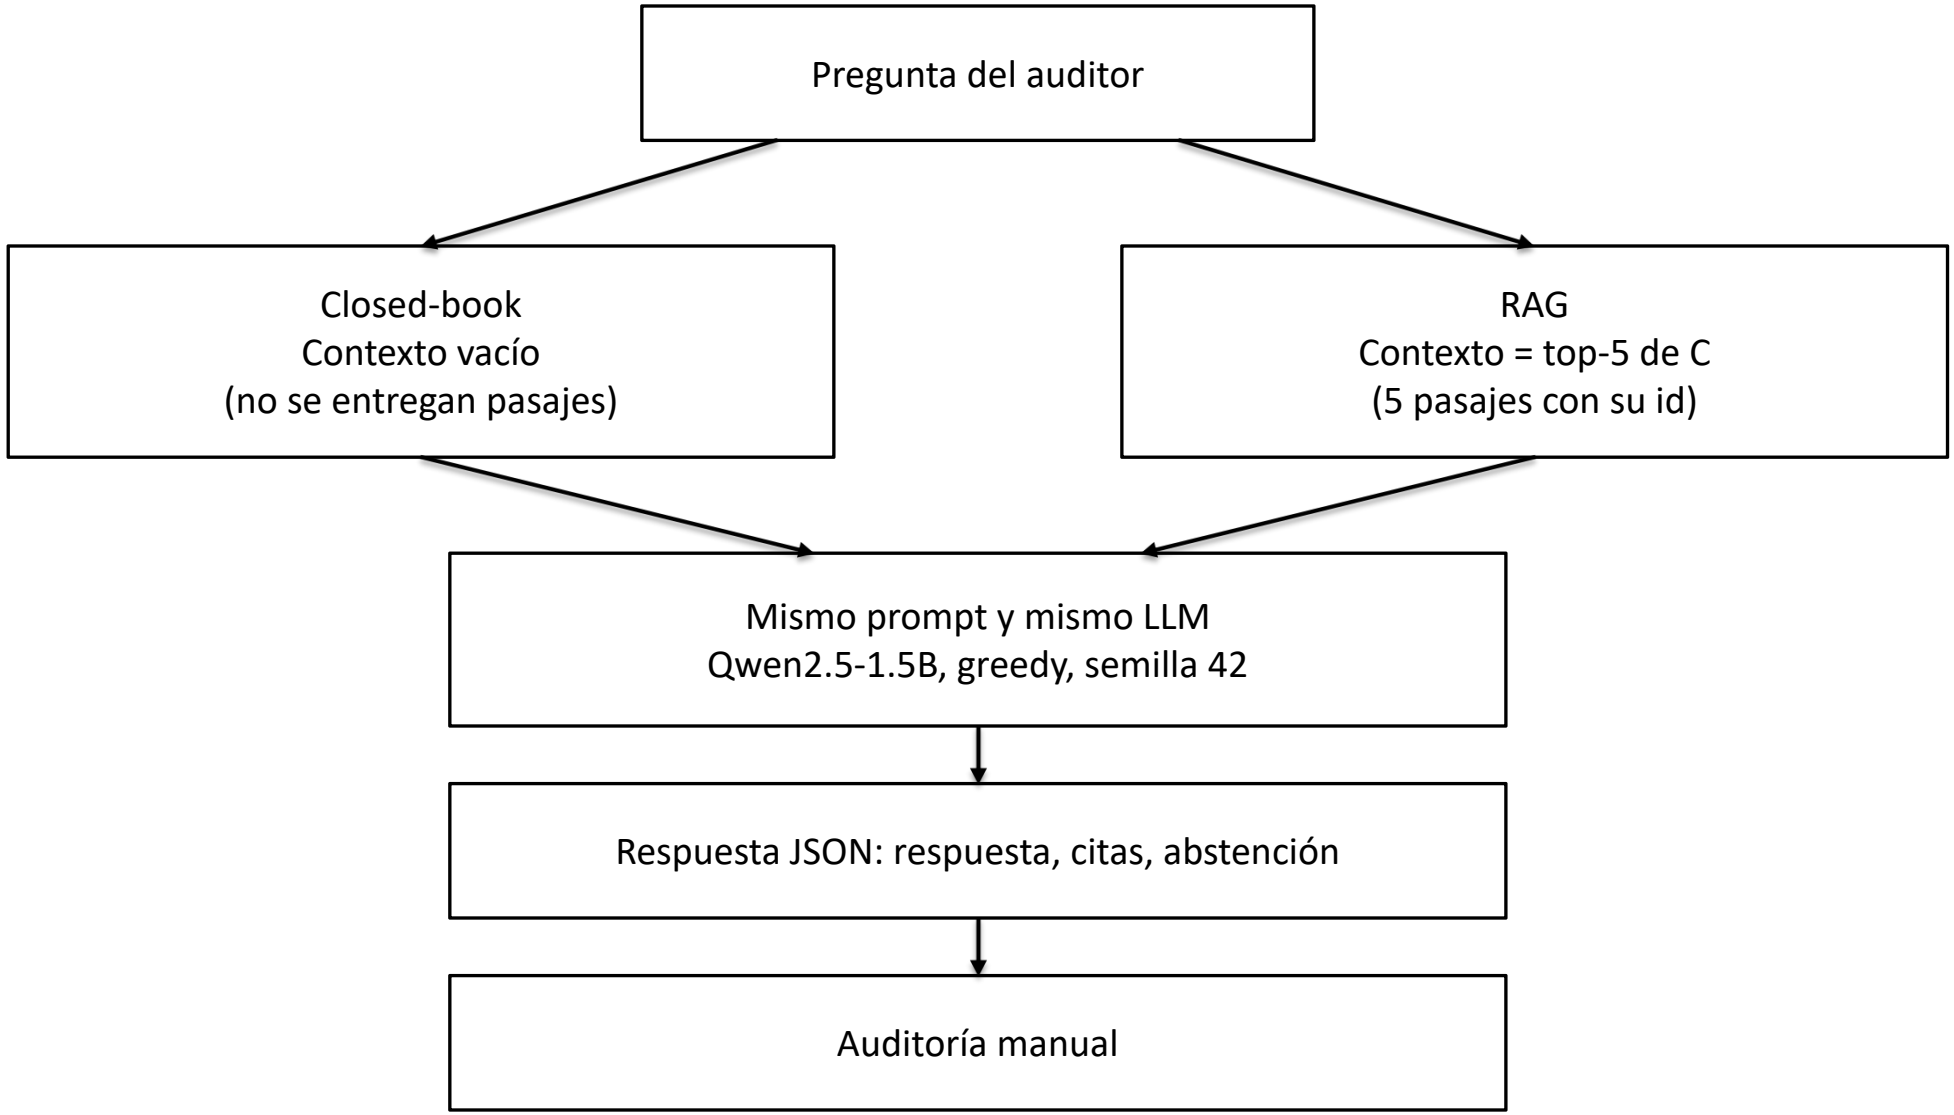
¿De qué trata el experimento?

- El experimento 1 buscó los pasajes. Aquí un LLM usa esos pasajes para responder
  - RAG: el modelo recibe la pregunta y los 5 mejores pasajes de la condición C, y responde citándolos
- Se compara contra closed-book: el mismo modelo, con la misma pregunta, pero sin pasajes
- Preguntas del experimento
  - ¿Entregar evidencia mejora la corrección y el sustento de las respuestas?
  - ¿El modelo se abstiene cuando no hay evidencia?
- La medida principal es una auditoría manual: leímos las respuestas y los pasajes

Qué entra al experimento

- 12 consultas fijadas antes de correr (marcadas exp2 en consultas.jsonl)
  - 10 tienen respuesta en el corpus: Q01, Q02, Q04, Q06, Q09, Q10, Q12, Q14, Q15 y Q17
  - 2 son controles sin evidencia: Q21 (sanciones) y Q22 (plazo de entrega)
  - En los controles lo correcto es abstenerse, porque el corpus no tiene ese dato
- Modelo: Qwen2.5-1.5B-Instruct, con la revisión fijada
- Contexto RAG: los 5 primeros pasajes de la condición C del experimento 1
- Respuestas de referencia (referencias.jsonl): se usan para auditar y se congelaron antes de correr

Qué se compara



El prompt

- El mensaje de sistema fija cuatro reglas
  - 1. Si hay pasajes, usa solo esos y pon en "citas" los ids de los que sustentan la respuesta
  - 2. Si no hay pasajes, responde con lo que sepas y deja "citas" vacía
  - 3. Si no tienes la información, no adivines: "abstencion": true y explica qué falta
  - 4. No inventes identificadores, nombres, montos ni fechas
- El mensaje del usuario trae la pregunta y el contexto
  - Cada pasaje empieza con su id entre corchetes, por ejemplo [E49-P05], seguido del encabezado del proceso y su texto
- El mismo prompt se usa en las dos condiciones; en closed-book el contexto dice "(no se entregan pasajes)"

La salida del modelo

{"respuesta": "El tóner Xerox 006R01830 fue comprado en el proceso RES-PROC-161-2025-RE-1, ítem 4",
"citas": ["E49-P05"],
"abstencion": false}

- Ejemplo real: respuesta del modelo con RAG a la consulta Q06
- respuesta: el texto breve en español
- citas: los ids de los pasajes que dice usar
- abstencion: true si decide que no tiene la información
- El formato fijo permite revisar automáticamente si el JSON es válido y si las citas existen
- Pero un JSON válido no dice si la respuesta es verdadera: eso lo revisa la auditoría

Qué se mantiene igual

- Mismo modelo: Qwen2.5-1.5B-Instruct con la revisión fijada
- Decoding greedy (do_sample = False), repetition_penalty = 1,0, máximo 192 tokens nuevos, semilla 42
- Mismo prompt, guardado antes de generar las respuestas
- Mismas 12 preguntas
- El formato del JSON se revisó antes solo con Q05 y Q16, que no forman parte del experimento
    - Así no se ajustó el prompt mirando las consultas que se evalúan
- Con greedy no hay azar: la diferencia entre closed-book y RAG se explica por el contexto

Por qué el mismo prompt en las dos condiciones

- Si closed-book tuviera la regla "usa solo los pasajes", se abstendría siempre
  - La comparación no diría nada, porque no habría respuesta que comparar
- Por eso la regla dice: si hay pasajes, usa solo esos y cítalos; si no hay, responde con lo que sepas
  - En ambos casos, abstente si no tienes la información
- Así las dos condiciones pueden responder o abstenerse, y se compara cómo lo hacen
- Por qué top-5 y no top-3
  - Varias respuestas necesitan dos pasajes del mismo proceso (postores y buena pro, objeto e ítem)
  - C tiene Recall@5 = 0,90 frente a Recall@3 = 0,88, y se fijó antes de correr

Cómo se mide

- Corrección de la respuesta (manual, contra la referencia)
  - correcta, parcial, incorrecta (afirma algo falso), no responde (se abstuvo aunque la evidencia estaba) o abstención correcta (control)
- Corrección de las citas
  - Automático: ¿la cita está en el contexto? ¿está en los qrels?
  - Manual: ¿la cita sustenta alguna afirmación? ¿la afirmación cita el pasaje que la sustenta?
- Faithfulness
  - La respuesta se divide en afirmaciones sueltas y cada una se marca como sustentada, no sustentada o contradicha
  - Se verifica contra el contexto entregado (en closed-book, contra el corpus)
- No se usa fluidez ni la opinión de otro LLM como prueba de calidad

Ejemplo de auditoría: consulta Q12

Pregunta	¿Quién fue el único postor en el mantenimiento del tomógrafo Siemens del Hospital General de Jaén?
Respuesta del modelo	SIEMENS HEALTHCARE S.A.C. fue el único postor
Cita del modelo	E50-P01
Pasaje que sí lo sustenta	E50-P05 (postores), que estaba en el puesto 1 del contexto

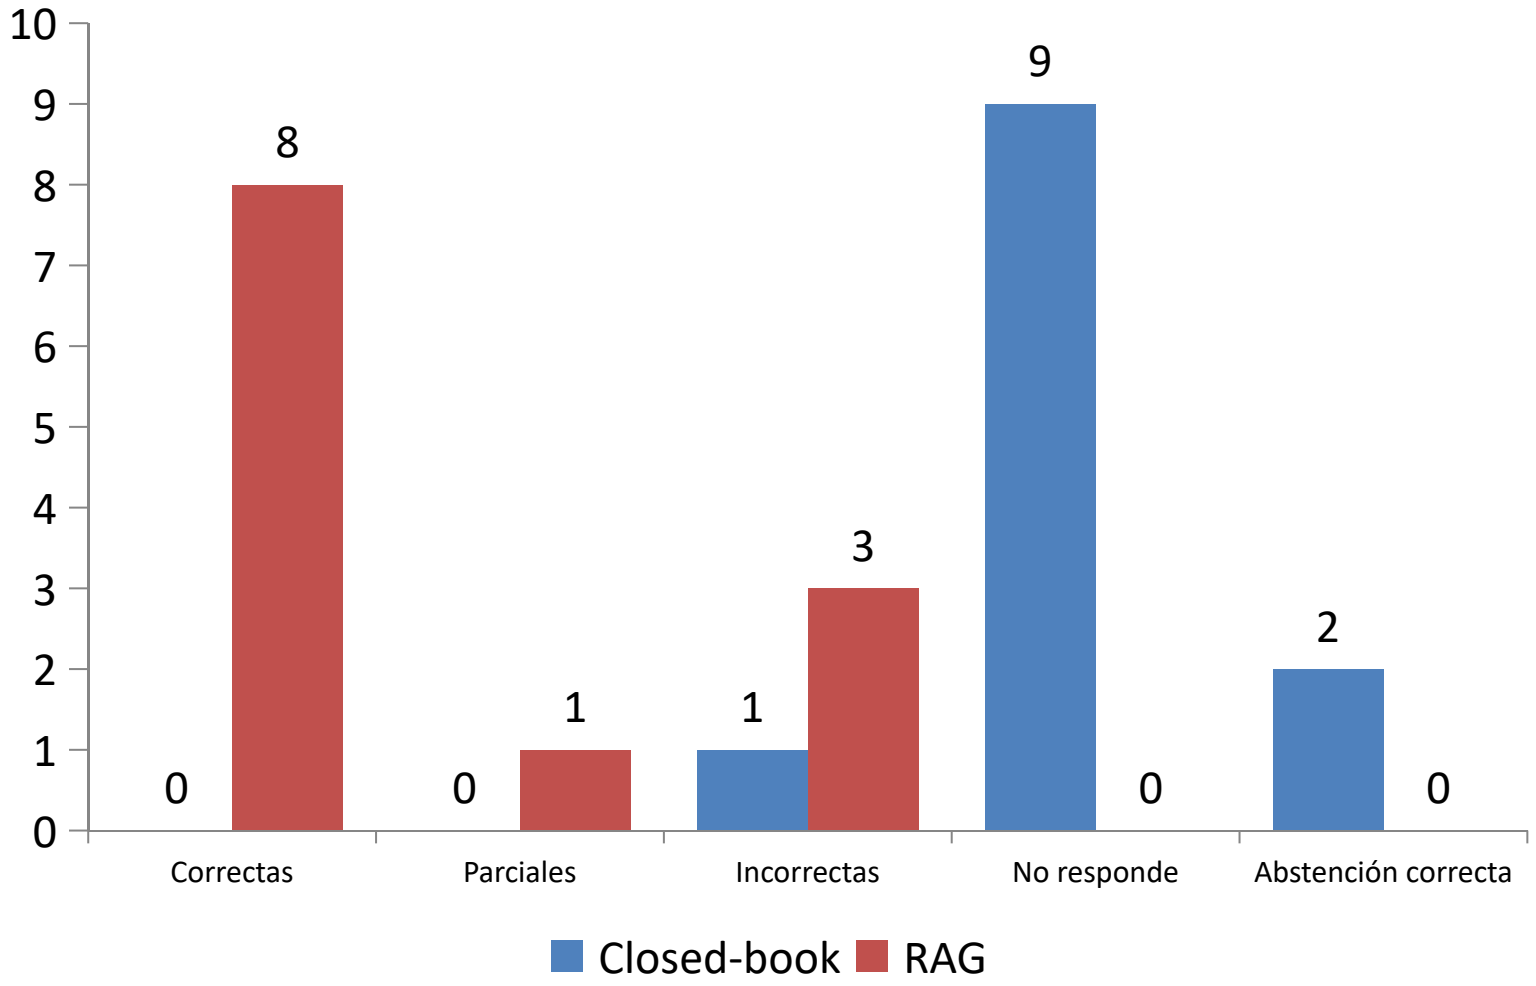
- Corrección de la respuesta: correcta
- Corrección de la cita: equivocada
  - E50-P01 es la convocatoria por proveedor único; no nombra a la empresa ni cuenta postores
  - La respuesta acierta, pero la cita no permite comprobarla
- Por eso se auditan por separado la respuesta y sus citas

Resultados: corrección de las respuestas

	Closed-book	RAG (top-5 de C)
JSON exacto y con formato	12/12	12/12
Correctas	0	8
Parciales	0	1
Incorrectas (afirman algo falso)	1	3
No responde (había evidencia)	9	0
Abstención correcta en los 2 controles	2/2	0/2

- 12 consultas por condición: 10 con respuesta y 2 controles
- La auditoría de cada respuesta está en auditoria_respuestas.csv

Resultados: gráfico



- Número de consultas de las 12
- Closed-book casi nunca responde
- RAG responde casi todo, a veces mal
- En los controles ocurre lo contrario

Interpretación: la corrección

- Sin evidencia el modelo casi no responde: 9 de 10 consultas sin respuesta
  - Se abstiene (8 veces) o dice que no tiene información (en Q09, con abstención en false: JSON válido pero incoherente)
  - Solo inventa una vez: en Q01 dice que la entidad fue el MTC, y fue la Agencia de Compras de las FF.AA.
- Con evidencia responde bien 8 de 10 y a medias 1
  - Pasa de no saber nada del SEACE a encontrar la respuesta en los pasajes
- Pero RAG pierde la abstención: 0 de 2 controles, frente a 2 de 2 en closed-book
  - El recuperador siempre entrega 5 pasajes, aunque ninguno sea relevante, y el modelo los usa para responder

Resultados: las citas

Medida	RAG
Citas dentro del contexto entregado (automático)	25/25
Citas que están en los qrels (automático)	12/25
Citas que sustentan alguna afirmación (manual)	12/25
Afirmaciones sustentadas que citan su pasaje (manual)	13/16

- Closed-book no cita nada, porque no tiene pasajes
- Todas las citas apuntan a un pasaje que sí estaba en el contexto, pero solo 12 de 25 sustentan algo
  - A veces el modelo cita los 5 pasajes del contexto aunque solo 1 o 2 dicen lo que afirma (Q02 y Q14)
- Los dos conteos de 12/25 no cuentan las mismas citas
  - En Q04 la cita E43-P05 está en los qrels, pero no sustenta el ganador ni el monto
  - En Q15 la cita E36-P06 sustenta el 79 %, pero no está en los qrels

Resultados: faithfulness

Condición	Afirmaciones	Sustentadas	Faithfulness
Closed-book	1	0	0,00
RAG (top-5 de C)	19	16	0,84

- Faithfulness = afirmaciones sustentadas dividido entre afirmaciones totales
- Con RAG, 16 de 19 afirmaciones están respaldadas por el contexto
- Las 3 que no lo están son de las consultas Q15, Q21 y Q22
  - Q15: contradicha por el pasaje; Q21 y Q22: ningún pasaje las respalda
- Closed-book casi no afirma nada (solo la del MTC en Q01, que es falsa)
  - Su faithfulness no se puede comparar, porque casi no hay afirmaciones que revisar

Errores analizados: los controles Q21 y Q22

Consulta	Qué dice el contexto	Respuesta del modelo con RAG
Q21: ¿qué sanción le impuso el Tribunal a MC INNOVATEC?	E01-P06: buena pro a MC INNOVATEC por S/ 184,500.00	Impuso una sanción de S/ 184,500.00 (cita E01-P06)
Q22: ¿cuál era el plazo de entrega de los switches Cisco?	Ningún pasaje habla de plazos	Fue de 30 días (cita E01-P02)

- En ambas debía abstenerse y no lo hizo
- Q21: convierte una adjudicación en una sanción, y la cita hace que la respuesta parezca sustentada
- Q22: inventa un dato (los plazos están en las bases en PDF, que el corpus no tiene)
- Closed-book, sin pasajes, se abstuvo en las dos

Errores analizados: Q15, Q12 y Q04

- Q15: el modelo se contradice
  - Dice "no aceptaba un producto equivalente" y en la frase siguiente "lo solicitado era AutoCAD o equivalente"
  - El objeto del proceso dice "o equivalente" y el ítem no; el modelo no señala esa diferencia
- Q12: respuesta correcta con cita equivocada
  - Cita la convocatoria (E50-P01) y no el pasaje de postores (E50-P05), que sí estaba en el contexto
- Q04: respuesta parcial
  - Da el ganador y el monto, pero omite los 15 postores y cita el pasaje de postores para el ganador
- La métrica automática cuenta esa cita de Q04 como correcta porque el pasaje está en los qrels

Costo del RAG

	Closed-book	RAG
Tokens de prompt (media)	271	943
Latencia media por respuesta (s)	20,2	35,3
Latencia p95 (s)	25,6	48,3

- Los 5 pasajes multiplican la entrada por 3,5
- La latencia sube un 75 %
  - El modelo tiene que leer el contexto antes de generar la primera palabra
- Medido en CPU y en una sola corrida: sirve de orden de magnitud

Lo que no funcionó: abstenerse con un umbral

Consulta	Puntaje del Cross-Encoder del primer pasaje	¿Hay evidencia?
Q08	-1,95 (el más bajo de todas)	sí, bien recuperada
Q21	-0,68	no (control)
Q19	1,53	sí
Q13	2,02	sí
Q22	2,30	no (control)

- Idea: no responder si el primer pasaje tiene un puntaje bajo
- No sirve: Q08 tiene evidencia y el puntaje más bajo, y Q22 queda por encima de Q19 y Q13
  - Un umbral que atrape Q21 también dejaría sin respuesta a Q08, que sí se podía responder
- No se implementó ningún umbral

Limitaciones

- 12 consultas: sirve para ver casos concretos, no para generalizar
- Un solo modelo pequeño (Qwen2.5-1.5B) en CPU; uno más grande podría abstenerse mejor, y no se probó
- La auditoría la hicimos nosotros, sin un segundo anotador ni medida de acuerdo
- El corpus no tiene las bases del proceso, que están en PDF: consultas como Q22 no se pueden responder
- Una sola corrida y una sola máquina, así que las latencias son orientativas

Conclusión

- Con evidencia, el mismo modelo pasa de no responder 9 de 10 consultas a responder bien 8 y a medias 1
  - Y 16 de sus 19 afirmaciones están respaldadas por el contexto
- Pero RAG le quitó la capacidad de abstenerse: 0 de 2 controles, frente a 2 de 2 en closed-book
  - El modelo usa los pasajes que recibe para inventar una respuesta con cita
- Una cita a un id válido no garantiza nada: 13 de 25 citas no sustentan lo que dice la respuesta
  - Una respuesta citada no es una respuesta verificada
- El costo: 3,5 veces más tokens de entrada y 75 % más de latencia